

Repasso de SVD

Dada $A \in \mathbb{K}^{m \times n}$, existen matrices:

- $U \in \mathbb{K}^{m \times m}$ unitaria ($U^* = U^{-1}$)
- $\Sigma \in \mathbb{K}^{m \times n}$ diagonal
- $V \in \mathbb{K}^{n \times m}$ unitaria ($V^* = V^{-1}$)

Tales que $A = U \Sigma V^*$ y

$$\Sigma = \begin{pmatrix} \sigma_1 & & & & \\ & \sigma_2 & & & \\ & & \ddots & & \\ & & & \sigma_m & \\ & & & & 0 \end{pmatrix} \quad \begin{array}{l} \text{si } m \leq n \\ (A = \boxed{}) \end{array}$$

$$\Sigma = \begin{pmatrix} \sigma_1 & & & & \\ & \ddots & & & \\ & & \ddots & & \\ & & & \sigma_n & \\ & & & & \ddots \\ & & & & & 0 \end{pmatrix} \quad \begin{array}{l} \text{si } m > n \\ (A = \boxed{}) \end{array}$$

$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_m \geq 0$ son los valores singulares.

$$A = U \Sigma V^* \Leftrightarrow A \cdot V = U \cdot \Sigma$$

$n \times m$ $m \times m$

$$\text{Si } V = \begin{pmatrix} | & | & | \\ v_1 & v_2 & \dots & v_m \\ | & | & \dots & | \end{pmatrix}, \quad U = \begin{pmatrix} | & | & | \\ u_1 & u_2 & \dots & u_m \\ | & | & \dots & | \end{pmatrix}$$

$$\Rightarrow A \cdot V = \begin{pmatrix} | & | & | \\ Av_1 & Av_2 & \dots & Av_m \\ | & | & \dots & | \end{pmatrix}$$

Si $m \leq n$ $n - m$ zeros

$$U \cdot \Sigma = \begin{pmatrix} | & | & | & | & \dots & | \\ \sigma_1 u_1 & \sigma_2 u_2 & \dots & \sigma_m u_m & \dots & 0 \\ | & | & \dots & | & \dots & | \end{pmatrix}$$

y

$m > n$

$$U \cdot \Sigma = \begin{pmatrix} | & | \\ \sigma_1 u_1 & \sigma_n u_m \\ | & | \end{pmatrix}$$

En ambos casos $A \cdot V = U \cdot \Sigma$ da que

$$Av_i = \sigma_i v_i \quad i = 1, \dots, \min\{m, n\} = p$$

Si $m \leq n$

$$Av_i = \sigma_i \cdot v_i \quad i = 1 \dots m$$

$$Av_i = 0 \quad i = m+1, \dots, n$$



Si $m > n$ $A v_i = \sigma_i v_i \quad i=1 \dots n$
 $A v_i$ libre $i=n+1, \dots, m$.

OBS: En ambos casos para los $\sigma_i = 0$
 se tendrá $A v_i = 0$.

Y en este caso vemos que $\sigma_i \cdot v_i = 0$
 también \Rightarrow esos v_i son libres.

¿ Cómo construimos V, \bar{Z}, V ?

1) Planteamos $A^* A \in \mathbb{K}^{n \times n}$ que es hermitiana
 \Rightarrow existe una BON de autovectores
 v_1, \dots, v_m y autosalores no negativos
 $\lambda_1 \geq \dots \geq \lambda_m \geq 0$ (los ordenamos)

$$\Rightarrow V = \begin{pmatrix} v_1 & v_2 & \dots & v_m \end{pmatrix}, \quad \sigma_i = \sqrt{\lambda_i}$$

$$\bar{Z} = \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \ddots & \\ & & & \sigma_m \end{pmatrix} \quad ; \quad \bar{V} = \begin{pmatrix} v_1 & & & \\ & \ddots & & \\ & & v_m & \\ & & & 0 \end{pmatrix}$$

$$\sigma_i = \sqrt{\lambda_i}$$

$$2) \text{ Para } \sigma_i \neq 0 \quad u_i = \frac{1}{\sigma_i} A v_i \\ i=1, \dots, s$$

Para $\sigma_i = 0$ tenemos $A v_i = 0$

Para los u_{s+1}, \dots, u_m que falten completamos a una BON

OBS: $A = U \sum V^*$ $\Leftrightarrow A \cdot V = U \sum$
 $A \in \mathbb{K}^{m \times n}$ $V \in \mathbb{K}^{m \times m}$, $U \in \mathbb{K}^{m \times n}$

$$1) \text{ Im } A = \{ A \cdot v : v \in \mathbb{K}^n \}$$

$$= \langle Aw_1, \dots, Aw_n \rangle$$

para cualquier $\{w_1, \dots, w_n\}$ base de \mathbb{K}^n

Como $V = (v_1 | \dots | v_n)$ tiene una

BON en sus columnas \Rightarrow

$$\text{Im } A = \langle Aw_1, \dots, Aw_n \rangle \quad p = \min\{n, m\}$$

Si asumimos $\left\langle \sigma_1 u_1, \dots, \sigma_p u_p \right\rangle$

$$\sigma_1 > \dots > \sigma_r > \sigma_{r+1} = 0 \downarrow = \langle \sigma_1 u_1, \dots, \sigma_r u_r \rangle$$

$$\downarrow = \langle u_1, \dots, u_r \rangle$$

porque $\sigma_i \neq 0$ para $i=1, \dots, r$

$\Rightarrow \text{Im } A = \langle u_1, \dots, u_r \rangle$ donde r :

$$\sigma_1 > \dots > \sigma_r > \sigma_{r+1} = 0$$

$\stackrel{\text{def}}{=}$

2) $(\text{Im } A)^\perp = \text{Nú } A^*$

$$(\text{Im } A)^\perp = \left\{ x \in \mathbb{k}^m : \begin{array}{l} \langle x, w \rangle = 0 \\ \forall w \in \text{Im } A \end{array} \right\}$$

$$= \left\{ x \in \mathbb{k}^m : \langle x, An \rangle = 0 \quad \forall n \in \mathbb{k}^m \right\}$$

$$= \left\{ x \in \mathbb{k}^m : \langle A^*x, n \rangle = 0 \quad \forall n \in \mathbb{k}^m \right\}$$

Donde usamos que $\langle x, An \rangle = \overline{\langle An, x \rangle}$

$$= \overline{\langle n, A^*x \rangle} = \langle A^*x, n \rangle$$

Así pues, $\langle A^*x, n \rangle = 0 \quad \forall n \in \mathbb{k}^m$

Si y solo si $\langle A^*x, e_i \rangle = 0$ para los vectores canónicos. Esto nos dice que $(A^*x)_{e_i} = 0$ para $i=1, \dots, m$ y entonces $A^*x = 0$ tiene:

$$(\text{Im } A)^+ = \{x \in \mathbb{K}^m : A^*x = 0\} = \text{Nú } A^*$$

■

Vemos la forma reducida:

$$\text{Si } \sigma_1 > \sigma_2 > \dots > \sigma_r > \sigma_{r+1} = 0$$

$$\Rightarrow A = U_r \Sigma_r V_r^* \in \mathbb{K}^{m \times m}$$

donde $V_r = \begin{pmatrix} & & \\ \vdots & \ddots & \\ & & \end{pmatrix} \in \mathbb{K}^{r \times m}$

$$\Sigma_r = \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{pmatrix} \in \mathbb{K}^{r \times r}$$

$$U_r = \begin{pmatrix} & & \\ u_1 & \cdots & u_r \\ & & \end{pmatrix} \in \mathbb{K}^{m \times r}$$

Por otros lados, si $k \leq r$

$$V_k = \begin{pmatrix} 1 & & 1 \\ N_1 & \dots & N_k \\ \vdots & & \vdots \end{pmatrix} \quad I_k = \begin{pmatrix} 0_1 & & \\ & \ddots & \\ & & 0_k \end{pmatrix}$$

$$U_k = \begin{pmatrix} 1 & & 1 \\ m_1 & \dots & u_k \\ \vdots & & \vdots \end{pmatrix}$$

$$A_k = V_k \sum_k U_k^*$$

$$= V_k (D_1 + \dots + D_k) U_k^*$$

con $D_1 = \begin{pmatrix} 0_1 & & \\ & 0 & \\ & & \ddots & \\ & & & 0 \end{pmatrix}, D_2 = \begin{pmatrix} 0 & & \\ & 0_2 & \\ & & \ddots & \\ & & & 0 \end{pmatrix}$

$$D_i = \begin{pmatrix} 0 & & \\ & 0_{ii} & \\ & & \ddots & \\ & & & 0 \end{pmatrix} \rightarrow \text{lugar } i$$

$$\Rightarrow V_k D_i U_k^* + \dots + V_k D_k U_k^*$$

$$V_k D_i U_k^* =$$

$$\begin{pmatrix} 1 & & 1 \\ N_1 & \dots & N_k \\ \vdots & & \vdots \end{pmatrix} \begin{pmatrix} 0 & & \\ & 0 & \\ & & \ddots & \\ & & & 0 \end{pmatrix} \begin{pmatrix} \dots \bar{u}_1 \dots \\ \vdots \\ \dots \bar{u}_k \dots \end{pmatrix}$$

$$= \begin{pmatrix} & & & \\ & \vdots & & \\ & N_i & & \\ & & \vdots & \\ & & & 1 \end{pmatrix} \begin{pmatrix} 0 & \cdots & \cdots & 0 \\ 0 & \cdots & \cdots & 0 \\ \cdots & \sigma_i \bar{u}_i & \cdots & 0 \\ 0 & \cdots & \cdots & 0 \\ \vdots & \cdots & \cdots & 0 \end{pmatrix}$$

$$= \begin{pmatrix} & & & \\ & \vdots & & \\ & \sigma_i N_i \bar{u}_i^1 & & \sigma_i N_i \bar{u}_i^k \\ & \vdots & & \vdots \\ & & & \vdots \end{pmatrix}$$

$$= \sigma_i \begin{vmatrix} N_i \end{vmatrix} \cdot \underline{\bar{u}_i^k}$$

$$\Rightarrow A_k = \sigma_1 N_1 \bar{u}_1^k + \dots + \sigma_k N_k \bar{u}_k^k$$

que tiene rango k.

Rango si $A = \cup \bar{\Sigma} V^*$

$\text{rg}(A) = \text{rg } (\bar{\Sigma}) = \# \text{ valores sing}$
 no nulos

Dem: $A \in \mathbb{K}^{m \times n}$

Vimos que $\text{Im } A = \langle Av_1, \dots, Av_n \rangle$

$$= \langle \sigma_1 u_1, \dots, \sigma_p u_p \rangle = \langle \sigma_1 u_1, \dots, \sigma_r u_r \rangle$$

\downarrow

donde $\sigma_r > \sigma_{r+1} = 0$

$\Rightarrow \text{rg}(A) = \dim \text{Im } A$

$$= \dim \langle \sigma_1 u_1, \dots, \sigma_r u_r \rangle$$

$$= r = \# \text{ val sing no nulos.}$$

Teorema:

Vale que si $A \in \mathbb{K}^{m \times n}$ y

$\text{rg}(A) = r \Rightarrow r \leq k \leq r$ se

tiene que A_k satisface

$$\|A - A_k\|_2 = \min \|A - B\|_2 = \sigma_{k+1}$$

$$B \in \mathbb{K}^{m \times n} : \text{rg}(B) = k$$

Es decir A_k es la "mejor"

aproximación en norma 2 de
matrices de la matriz A a
una matriz de rango k .

Resumen

$m > n$

$$m \times m$$

$$\boxed{A} =$$

$$m \times m$$

$$\boxed{U}$$

$$m \times m$$

$$\boxed{\Sigma_k}$$

$$m \times m$$

$$\boxed{V_k^t}$$

$$V_k \in \mathbb{R}^{m \times k}$$

$$U_k \in \mathbb{R}^{m \times k}$$

$$A_k = U_k \Sigma_k V_k^* \quad \text{de rango } k < \text{rg}(A)$$

OBS: $U_k^* U_k = \text{Id}_{k \times k}, \quad U_k U_k^* \in \mathbb{R}^{m \times m}$

Recordar: Si S es un subesp. $\{w_1, \dots, w_k\}$ bon de S $\Rightarrow [P_S]_{EE} = (\underbrace{w_1 \dots w_k}_W) (\underbrace{w_1 \dots w_k}_W)^*$
es decir $P_S(x) = W W^* x$.

En este caso usaremos la notación

P_{U_k} para la proyección en $S = \langle u_1, \dots, u_k \rangle$
es decir, $P_{U_k}(x) = U_k U_k^* x$

o análogamente $[P_{U_k}]_{EE} = U_k U_k^*$

Veamos que $A_k x = P_{U_k} A x$, es decir

Veamos que $A_k = U_k U_k^* A$

$$U_k U_k^* A = U_k \underbrace{U_k^*}_{\Sigma V^*} U \Sigma V^*$$

$$U_k^* (U_k | \mu_{k+1} \dots \mu_m)$$

$$= (\text{Id} | \underbrace{U_k^* [\mu_{k+1} \dots \mu_m]}_{= 0})$$

porque $\mu_1 \dots \mu_m$
es BOW.

$$\Rightarrow U_k U_k^* A$$

$$= U_k (\text{Id} | 0) \Sigma V^*$$

$$= U_k (\text{Id}_k | 0) \begin{pmatrix} \Sigma_k | 0 \\ 0 | \Sigma_{k+1 \dots m} \end{pmatrix} \begin{pmatrix} U_k^* \\ U_{k+1 \dots m}^* \end{pmatrix} \xrightarrow{\substack{\text{el resto de} \\ \text{los filos} \\ \text{desde } N_{k+1}}} \dots$$

donde llamamos $\Sigma_{k+1 \dots m}$ al resto de
la matriz diagonal de Σ desde el
valor singular $\sigma_{k+1} \dots$.

$$\Rightarrow U_k U_k^* A$$

$$= U_k \left(\sum_k I_0 \right) \left(\frac{V_k^*}{\|V_{k+1..n}\|} \right)$$

$$= U_k \sum_k V_k^* = A_k \Rightarrow A_k = P_{U_k} A$$

Análogamente

$$V_k^* V_k = I_{k \times k} \quad V_k V_k^* = P_{V_k}$$

$$\Rightarrow A_k^* = P_{V_k} A^*$$

Es decir, la matriz A_k de rango k que se le sue mejor approxima a la matriz A en norma 2 viene dada por la proyección ortogonal de cada columna de A sobre el subespacio generado por las primeras k columnas de U .

Geometricamente esto nos dice que si tenemos muchos datos en \mathbb{R}^3

$$A = \boxed{\quad \quad \quad}^{C_i(A)}$$

$3 \times n$


$n > 3 \quad \text{rg}(A) = 3$

datos "centrados"
con

A_2 la matriz de rango 2 que
mejor approxima a A en norma 2

$$\text{es } A_2 = P_{\langle u_1, u_2 \rangle} A$$

$$\text{Es decir } C_i(A_2) = P_{\langle u_1, u_2 \rangle} C_i(A)$$



Valores singulares y norma 2

Vemos que:

Teo: $A \in \mathbb{K}^{m \times n} \Rightarrow \|A\|_2 = \sigma_1$

Además, si $A \in \mathbb{K}^{n \times n}$ es invertible

$$\Rightarrow \|A^{-1}\|_2 = \frac{1}{\sigma_n} \quad \text{ya que}$$

val sing de A^{-1} son $1/\sigma_i$, si val

sing de A .

Ejercicio: Probar $A \in \mathbb{K}^{n \times n}$ es invertible
si y solo si $\sigma_n > 0$.

Hasta, si A es invertible

$$\text{cond}_2(A) = \sigma_1 / \sigma_n.$$

OBS: $\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|$

Vemos que $\max_{\|x\|=1} \|Ax\| = \sigma_1$

Además, $\|Ax\|_2 = \|\Sigma V^* x\|_2 = \left\| \sum_i \underbrace{\sigma_i V^*}_{y} \underbrace{x}_y \right\|_2$
 Uníntaria

Si $y = V^* x \in \mathbb{R}^m$, $\Sigma \in \mathbb{R}^{m \times m}$

$$\text{si } \Sigma = \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_m \end{pmatrix} \quad \Sigma \cdot y = \begin{pmatrix} \sigma_1 y_1 \\ \vdots \\ \sigma_m y_m \end{pmatrix} \quad m \leq m$$

$$\text{si } \Sigma = \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & 0 \end{pmatrix} \quad \Sigma \cdot y = \begin{pmatrix} \sigma_1 y_1 \\ \vdots \\ 0 \\ \vdots \\ 0 \end{pmatrix} \quad m > m$$

Si completamos $\sigma_{m+1} = \dots = \sigma_n = 0$ en $m \leq n \Rightarrow$

$$\|\Sigma y\|_2^2 = \sum_{i=1}^n (\sigma_i y_i)^2 = \sum_{i=1}^n \sigma_i^2 y_i^2 \geq \sigma_m^2 (y_1^2 + \dots + y_n^2)$$

$$\Rightarrow \|\Sigma y\|_2 \geq \sigma_m \|y\|_2$$

$$\Rightarrow \|\Sigma V^* x\|_2 \geq \sigma_m \|V^* x\|_2 = \sigma_m \|x\|_2$$

$$\Rightarrow \|Ax\|_2 \geq \sigma_m \|x\|_2 \rightarrow \|Ax\|_2 \geq \sigma_m$$

$\text{si } \|x\|_2 = 1$

Y como $\|AN_m\|_2 = \sigma_m$ tenemos

$$\min_{\|x\|_2=1} \|Ax\|_2 = \sigma_m \quad \begin{array}{l} (\text{que sea } 0 \text{ si } \\ m < n) \end{array}$$

Pseudoinversa (de Moore-Penrose)

Da la SVD de $A = U \Sigma V^*$

construimos la pseudoinversa de A

$$A^+ = V \Sigma^T U^* \text{ donde } \Sigma^T$$

se construye trasponiendo Σ y
cambiando cada $\sigma_i \neq 0$ por $\frac{1}{\sigma_i}$

Proposición:

1) $AA^+A = A$ y $A^+AA^+ = A^+$

(pero en general no se cumple

que $AA^+ = \text{Id}$ ó $A^+A = \text{Id}$)

2) Si $A \in \mathbb{R}^{n \times m}$ es invertible $\Rightarrow A^T = A^{-1}$

Dem:

$$1) \underbrace{U\Sigma V^*}_{\text{Id}} \Sigma^T \underbrace{U^*}_{\text{Id}} \Sigma V^*$$

$$= U\Sigma \Sigma^T \Sigma V^*$$

$$\text{Si } \Sigma = \left(\begin{array}{c|c} \sigma_1 & \\ \vdots & \ddots \\ \sigma_r & \\ \hline 0 & 0 \end{array} \right) \quad \sigma_r \neq 0$$

$$\Sigma^T = \left(\begin{array}{c|c} \sigma_1^{-1} & \\ \vdots & \ddots \\ \sigma_r^{-1} & \\ \hline 0 & 0 \end{array} \right)$$

$$\Rightarrow \Sigma \Sigma^T \Sigma = \Sigma \quad \checkmark$$

Ej: Demostrar lo que falta

2) A invertible $\Leftrightarrow \sigma_n > 0 \dots$

teo: $Ax=b$ $A \in \mathbb{k}^{m \times n}$, si existen soluciones $\Rightarrow z = A^T b$ es una sol y no hay infinitas \Leftrightarrow de menor norma 2.

Tlc: $Ax = b$ tiene sol si $AA^Tb = b$

Dem:

$$\Rightarrow \exists n: An = b$$

$$\Rightarrow b = An = AA^TAn = AA^Tb$$

$$\Leftrightarrow \underbrace{AA^Tb}_x = b \Rightarrow \exists x: Ax = b.$$

Tlc: Dado $A \in \mathbb{K}^{m \times n}$, $b \in \mathbb{K}^m$

$\forall AA^Tb = b$, x es sol de $Ax = b$

sii $x = A^Tb + (I - A^TA)y$ con
 $y \in \mathbb{K}^n$.

Dem:

$$\begin{aligned}\Leftrightarrow & A(A^Tb + (I - A^TA)y) \\ &= AA^Tb + Ay - \underbrace{AA^TAy}_{Ay}\end{aligned}$$

$$= AA^T b = b$$

\Rightarrow Dado $z: Az = b$

$$z = \underbrace{A^T A z}_b + \underbrace{(z - A^T A z)}_{(I - A^T A)z}$$

y

OBS: pueden estar repitiéndose soluciones.

Ejercicio: $A \in \mathbb{k}^{m \times n}$

Si $m > n$ y $\text{rg}(A) = n \Rightarrow$

$$A^T = (A^* A)^{-1} A^* \quad y \quad A^T A = \text{Id}$$

Si $m < n$ y $\text{rg}(A) = m \Rightarrow$

$$A^T = A^* (A A^*)^{-1} \quad y \quad A^T A = \text{Id}$$

Aplicaciones

$$A = \begin{pmatrix} A \\ m \times m \end{pmatrix} = \begin{pmatrix} U \\ m \times m \end{pmatrix} \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_m \\ \hline & & 0 \end{pmatrix}_{m \times m} \begin{pmatrix} V^* \\ m \times m \end{pmatrix}$$

Si $\text{rg}(A) = r < m \Rightarrow \sigma_{r+1} = \dots = \sigma_m = 0$

$$\Rightarrow A = A_r = \begin{pmatrix} U_1 & \cdots & U_r \\ m \times r \end{pmatrix} \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{pmatrix} \begin{pmatrix} V_1 & & \\ & \ddots & \\ & & V_r \end{pmatrix}_{r \times m}$$


OBS: $\underbrace{\begin{pmatrix} -v_1 & \cdots & -v_r \\ -v_r & \cdots & -v_1 \end{pmatrix}}_{r \times m} \underbrace{\begin{pmatrix} 1 & & \\ v_1 & \cdots & v_r \\ \vdots & & \vdots \end{pmatrix}}_{n \times m} = \mathbb{I}_r$

$$\Rightarrow A \cdot \begin{pmatrix} 1 & & \\ v_1 & \cdots & v_r \\ \vdots & & \vdots \end{pmatrix} = \begin{pmatrix} 1 & & \\ U_1 & \cdots & U_r \\ \vdots & & \vdots \end{pmatrix} \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{pmatrix}$$

El resto $v_{r+1} \dots v_m$ están en $N(A)$.

Aplicaciones:

- Reducción de dimensionalidad.
 m características (altura, peso, etc)



Puede haber
características
redundantes


$$\text{rg}(A) = r$$

si $k < r$

σ_{k+1} nos dice cuánta informa-
ción perdemos si usamos A_k
en lugar de $A = A_k$.

- Imágenes (en color, grises)

Grises 1000



pixels ~
 1000×2000

¿Cuántos tweets consumir?

$$A = U \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_{1000} & \\ & & & 0 \end{pmatrix} V^T$$

✓

- Algoritmos de recomendación

pelis 20.000 = n

usando svd

$$A = U \Sigma V^T$$

$m \times m$

$n \times n$

$m \times m$

$m \times m$

500.000 = m

$m \times m$


$m \times m$

Uso reducida: $r = \text{rg}(A)$

$$A = A_r = \begin{pmatrix} | & | \\ v_1 & \dots & v_r \\ | & | \end{pmatrix} \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{pmatrix} \begin{pmatrix} -v_1 & & \\ & \ddots & & \\ & & -v_r & \end{pmatrix}$$

$m \times r$

$r \times m$



"Las "características" son descond-
 cidas."

Cada

$$a_{ij} = q_i \cdot p_j$$

fila i de Q_r
 $\sqrt{2}$ \rightarrow t \rightarrow $\sqrt{2} V_r^* P_r$
 Col j de

"concentra relación
 entre caract y
 características peli j .
 de usuario i

Se busca

a_{ij} de la q^t
queremos

$$\min_{P, q} \sum_i \left(r_{i,j} - q_i^t p_j \right) + \lambda \|Q_r\|_F^2 + \lambda \|P_r\|_F^2$$

\downarrow

$$S = \{(i, j) : r_{i,j} \text{ es conocido}\}$$

Conjunto de entrenamiento.

- Principal Components Analysis

Idea es dar un sistema de coordenadas jerárquico basado en los datos, {características}

$$A = \begin{pmatrix} a_1 & \dots \\ a_2 & \dots \end{pmatrix} \in \mathbb{R}^{m \times n}$$

personas

Cada a_i es un conjunto de medidas del mismo experimento

Por ej datos demográficos:

altura, peso, género, etc.

y cada fila sería un individuo

($m >> n$)

Queremos determinar los características dominantes de los datos,

1. Calculamos la media (promedio) vectorial

$$\bar{a} = \frac{1}{m} \sum_{j=1}^m a_j$$

En cada lugar \bar{a}_i está el promedio de i características

y definimos


$$\bar{A} = \begin{pmatrix} \cdots & \bar{a} & \cdots & \cdots \\ & \cdots & \bar{a} & \cdots & \cdots \\ & & & \cdots & \bar{a} & \cdots \end{pmatrix} = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \cdot [\bar{a}]$$

$\Rightarrow B = A - \bar{A}$ es una matriz que tiene los datos "centrados".


Ej. en \mathbb{R}

$$a_1 = -2, a_2 = -1$$

$$a_3 = 2, a_4 = 5$$



$$\bar{a} = \frac{-2 - 1 + 2 + 5}{4} = \frac{4}{4} = 1$$



Var

$$\frac{1}{4} \left((-3)^2 + (-2)^2 + 1^2 + 4^2 \right)$$

2. Calculamos autovalores

y autorectores de $B^t \cdot B$

(o decir, calculamos

los $\sigma_i = d_i^2$ valores propios

y los vectores V de la SVD de B)

$$B = U \Sigma V^t$$

→ nuevas direcciones

$$T = B \cdot V = U \Sigma$$



componentes propias

1^{er} comp →

$$B \cdot v_1 = \sigma_1 u_1$$

2^{da} comp

$$B \cdot v_2 = \sigma_2 u_2$$

$$B \cdot \vec{v}_1 = v_1^1 C_1(B) + \dots + v_1^n C_n(B) \text{ con } \vec{v}_1 = (v_1^1, \dots, v_1^n)$$

Es decir \vec{v}_1, \vec{u}_1 es una comb. lineal de col de la matriz de datos B .

$B^t B$ = matriz de covarianza

$$B^t B = \begin{pmatrix} b_1 & \dots & b_m \\ b_1 & \dots & b_m \\ \vdots & \ddots & \vdots \\ b_1 & \dots & b_m \end{pmatrix} \begin{pmatrix} b_1 \\ \vdots \\ b_m \end{pmatrix}$$

$$B = \begin{pmatrix} b_1 \\ \vdots \\ b_m \end{pmatrix} \rightarrow \text{individuo 1} \quad \text{individuo } m$$

↑ ↑ ↑
peso altura m características

Datos
en \mathbb{R}^m

$$B^t \cdot B = \begin{pmatrix} b_1' & \dots & b_m' \\ \vdots & \ddots & \vdots \\ b_1^m & \dots & b_m^m \end{pmatrix} \begin{pmatrix} b_1'' \\ \vdots \\ b_m'' \end{pmatrix} \quad \begin{pmatrix} b_1^{(1)} & \dots & b_1^{(m)} \\ \vdots & \ddots & \vdots \\ b_m^{(1)} & \dots & b_m^{(m)} \end{pmatrix}$$

↓ ↓ ↓
caract¹ de caract¹ de caract¹ de
indiv 1 indiv m c/indiv

$$\langle b_1, b_1 \rangle = \|b_1\|^2$$

$$\langle b_1, b_2 \rangle = \|b_1\| \|b_2\| \cos \theta$$

será mayor si $\theta = 0$


y menor si $\theta = \pi$



Si $\theta = \frac{\pi}{2}$ no tienen correlación

etc.

$B^t B$ matriz de covarianzas



Queremos

$$\min \sum_{i=1}^n \|r_i\|^2$$

Dados $\bar{a}_1 \dots \bar{a}_m \in \mathbb{R}^n$

$$\|\bar{a}_i\|^2 = \|r_i\|^2 + \|z_i\|^2$$

luego

$$\min \sum \|r_i\|^2$$

equivale a

$$\max \sum \|z_i\|^2$$

que es la norma

max norma de la

la proyección.

Es decir, la recta conserva
la variabilidad !

Y ésta es una propiedad
esperable !